

Plan de cours : Science des données I : visualisation et inférence

Année académique 2024-2025

Enseignants

- Enseignant : Philippe Grosjean
- Assistant : Guyliann Engels

Présentation du cours

La science des données s'intéresse à l'analyse des données sous toutes ses formes. Cette discipline requiert des compétences en informatique, en mathématiques et dans le domaine d'expertise. La Science fait actuellement face à de nombreux changements suite à l'introduction de l'Open Science, de l'Open Data, de l'augmentation exponentielle des données... Les biologistes doivent être capables d'évoluer dans ce contexte grâce à une bonne connaissance de la science des données biologiques.

Ce premier cours s'inscrit dans une formation continue sur trois années successives. À la fin de ce premier cours, les étudiants seront capables de réaliser des analyses biologiques usuelles et de présenter clairement leurs résultats de manière reproductible avec des outils informatiques et statistiques professionnels.

La fiche ECTS reprend toutes les informations essentielles : <http://applications.umons.ac.be/web/fr/pde/2024-2025/ue/US-B2-SCBIOL-006-M.htm>

Organisation

Le cours de Science des données I : visualisation et inférence est une unité d'enseignement (UE) de six crédits. Il est divisé en deux activités d'apprentissages (AA) de trois crédits chacune : Science des données I : visualisation (Q1) et Science des données I : inférence (Q2). Ce cours est constitué de dix modules. Chaque module représente une charge moyenne de travail de 15 à 18h dont 6h en présentiel et le reste en travail personnel à domicile. Vous pouvez retrouver à l'horaire les plages en présentiel. Le travail à distance est à réaliser entre ces sessions. Toutes les heures en présentiel sont assimilées à des heures de travaux pratiques encadrés avec **présence obligatoire**. Chaque absence doit être justifiée.

Modules

Science des données I : visualisation (Q1)

- Initiation et visualisation I, R, RStudio, git et graphique en nuage de points
- Visualisation II, histogramme, graphique de densité, graphique en violon
- Visualisation III, graphique en barres, graphique en camembert, boîte de dispersion, composition et moteurs graphiques
- Traitement des données I, type de variables, tableau cas par variables, importation, conversion et manipulation des données
- Traitement des données II, tableau de contingence, population, échantillonnage, acquisition, traitement multi-tableaux

Science des données I : inférence (Q2)

- Probabilités et test de corrélation
- Lois de distributions statistiques et test Chi carré
- Intervalle de confiance, test de Student, test de Wilcoxon
- Analyse de variance I, ANOVA à un facteur, test de Kruskal-Wallis, tests post-hoc
- Analyse de variance II, ANOVA à deux facteurs, syntaxe du langage R

Méthode pédagogique

Ce cours est donné en classe **inversée** avec l'ensemble du matériel pédagogique disponible via le lien <http://bds.sciviews.org/>. Les étudiants seront actifs à chaque étape de l'apprentissage. Chaque module de cours comprend des exercices classés en quatre niveaux de difficulté croissante.

- niveau 1 : découverte des notions avec des exercices rapides et ciblés intégrés au sein du cours en ligne
- niveau 2 : application des notions dans des exercices sous la forme de tutoriel cadré
- niveau 3 : transfert de ces notions dans des projets individuels guidés et réalisés sur des données biologiques
- niveau 4 : réalisation d'analyses libres dans des projets de groupe et sur des données biologiques nouvelles

De plus, des challenges pratiques et des interrogations vont être réalisés durant les séances en présentiel. Néanmoins, la plus grande partie de votre temps en séance sera consacrée à l'analyse de données biologiques au sein des exercices de niveau 3 et 4.

L'apprentissage nécessite de poser régulièrement des questions. Le canal privilégié pour ces échanges est constitué des “issues” dans GitHub, accessibles depuis le site du cours. Vous pouvez également nous contacter par mail à l'adresse sdd@sciviews.org, mais uniquement pour les questions à caractère privé par rapport aux autres étudiants, pas pour les questions sur la matière elle-même.

Évaluation

L'activité dans les différents exercices est enregistrée pour chaque étudiant et est utilisée pour une évaluation continue. **Il n'y a pas d'examen en session, ni d'examen de seconde session pour cette matière.** La pondération entre les AA du Q1 et du Q2 est de 50/50 avec la note finale arrondie à la demi unité près. Il faut avoir réalisé au minimum 80% des exercices de chaque module pour qu'il soit pris en compte dans l'évaluation.

La note de chaque AA est obtenue par addition des composantes suivantes :

- 6% pour les exercices à préparer en distanciel :
 - 2%, exercices N1 (H5P + shiny)
 - 4%, exercices N2 (learnr)
- 34% pour les projets, soit :
 - 6%, projets individuels cadrés N3
 - 28%, projets de groupe N4
- 60% pour des interrogations (ou challenges) relatives à un module (12%) ou deux modules (24%). En cas d'une absence justifiée, l'évaluation pourra être réalisée dans les sept jours suivants. Toute absence injustifiée est sanctionnée par un zéro pour l'évaluation correspondante.

Pour les raisons énumérées suivantes, il est envisageable d'obtenir entre un demi et un point bonus sur la note finale sur 20 pour :

- une participation active et remarquable dans la résolution d'“issues”
- une aide significative apportée à vos collègues sous la forme d'explications de la matière en séance
- une réflexion approfondie sur la matière (hors aspects purement techniques) accompagnée d'échanges avec les encadrants
- une progression particulièrement importante dans l'apprentissage

Entraide versus plagiat

L'entraide entre les étudiants est encouragée, mais il faut citer ses sources. Le plagiat est par contre totalement **interdit** et sévèrement puni à l'UMONS. Les étudiants devront bien comprendre la différence entre les deux dans le cadre du cours.

Usage de l'intelligence artificielle générative

Conformément à la Charte d'utilisation des systèmes d'intelligence artificielle générative pour les travaux universitaires à l'UMONS, l'usage de l'intelligence artificielle générative est autorisé. Il est essentiel d'adopter une utilisation responsable, critique et transparente de l'IA.

Il est **obligatoire** de mentionner dans la section *Matériel et méthodes* de tous les projets réalisés, l'utilisation de l'IA, du modèle consulté, ainsi que le contexte dans lequel celui-ci a été utilisé.

L'utilisation de l'IA en tant qu'outil d'assistance linguistique, de recherche d'informations ou encore d'assistance à la programmation est autorisée. Le code proposé devra toutefois respecter le "dialecte" SciViews::R qui diffère significativement du R de base. **Tout code issu d'une IA en R de base ou en tidyverse devra être converti manuellement en SciViews::R sous peine de pénalités.**

Restez cependant critique vis-à-vis de l'information proposée par l'IA.

Équipement requis

- un ordinateur (en option)

Les heures en présentiel sont données dans des salles informatiques équipées d'ordinateurs. Il est conseillé d'utiliser son ordinateur personnel pour les étudiants qui en disposent. Cela simplifie le travail en distanciel.

- des écouteurs

Des vidéos sont présentes dans le cours en ligne et il faut pouvoir les écouter avec le son sans déranger ses voisins.

- un câble ethernet (en option)

Il s'agit d'un câble RJ-45 non croisé de catégorie 5E ou plus d'au moins 1m, avec adaptateur si nécessaire pour le connecter sur votre ordinateur (par exemple, USB -> RJ-45). La connexion filaire permet un accès à Internet plus stable et plus rapide que le Wifi.

L'UMONS met également des salles informatiques à disposition des étudiants qui ne disposent pas de leur propre PC. Le travail dans les salles informatiques doit se faire dans le respect de la **charte informatique de l'UMONS**, voir https://go.sciviews.org/charte_info.

Protection de la vie privée

La collecte des données personnelles des étudiants dans le cadre de ce cours se fait en respect du RGPD, voir <https://wp.sciviews.org/politique-de-confidentialite/>.

Ressources

- Site web du cours <http://bds.sciviews.org/>
- Horaire des cours <https://hplanning2024.umons.ac.be/invite>
- Ressources Moodle :
 - Science des données I : visualisation <https://moodle.umons.ac.be/course/view.php?id=1387>
 - Science des données I : Inférence <https://moodle.umons.ac.be/course/view.php?id=3385>
- Fiche ECTS du cours : <http://applications.umons.ac.be/web/fr/pde/2024-2025/ue/US-B2-SCBIOL-006-M.htm>
- Définition du plagiat et les sanctions à l'UMONS : [https://alumni.umons.ac.be/sites/SAP_Etudiants/SitePages/Plagiat\(1\).aspx](https://alumni.umons.ac.be/sites/SAP_Etudiants/SitePages/Plagiat(1).aspx)
- Je ne plagie pas ... enfin, je pense : https://alumni.umons.ac.be/sites/SAP_Etudiants/SitePages/Plagiat.aspx
- Charte informatique de l'UMONS : https://go.sciviews.org/charte_info
- Charte d'utilisation des systèmes d'intelligence artificielle générative dans les travaux universitaires à l'UMONS : <>